Team Peanuts

BENCHMARK

TeamData : GROUPE 8

Bouimedj Wafi
Bouzidi Mohamed Amine

Pour : M.NGUYEN

1. Présentation du besoin métier

Le projet consiste à développer une interface de commande intelligente permettant aux clients de Givaudan de communiquer avec un assistant conversationnel en langage naturel.

Par exemple, un client pourrait écrire :

“Bonjour, je souhaite commander 50 kg d'un arôme vanille pour une application dans des produits laitiers. Je voudrais une livraison dans trois semaines.”
Le LLM doit être capable de :

- Comprendre les demandes formulées en langage naturel.
- Identifier les produits concernés (parfums, arômes, ingrédients).
- Extraire les informations de commande : référence, quantité, unité, application, délai de livraison.
- Poser des questions lorsqu'une information est manquante.
- Transformer la demande en données structurées exploitables par Python.
- Vérifier les informations avant de transmettre la commande au système métier.
- Gérer plusieurs langues, notamment le français et l'anglais.

Point important : notre LLM ne décide pas de valider seul une commande. Il doit comprendre et structurer la demande ; la validation des références, des stocks, des prix et de la commande doit être réalisée par le système métier.

2. Pourquoi choisir Qwen avec Ollama ?

Le choix de Qwen présente plusieurs avantages pour notre projet.

A. Capacités linguistiques

Qwen2.5 prend en charge plus de 100 langues et dialectes selon sa documentation officielle. C'est intéressant pour Givaudan, dont les clients peuvent communiquer dans différentes langues, notamment :

- Français.
- Anglais.
- Espagnol.
- Allemand.
- Chinois.

Cela permet d'envisager une interface de commande multilingue sans développer un modèle distinct pour chaque langue.

B. Extraction d'informations et compréhension

Qwen peut comprendre une demande formulée de manière naturelle et en extraire les éléments importants.

Cette capacité est particulièrement importante puisque notre application Python doit pouvoir récupérer directement les informations pour les transmettre à une base de données ou à un système de gestion de commandes.

C. Compatibilité avec Python

Ollama dispose d'un SDK Python permettant d'interagir directement avec Qwen.
Il propose notamment :

- L'envoi de messages à un modèle.
- La gestion de conversations.
- L'utilisation de fonctions Python (Function Calling).
- La génération de réponses structurées en JSON avec un schéma défini.

Le Function Calling est particulièrement pertinent : le modèle peut demander à Python d'exécuter une fonction pour rechercher une référence produit, vérifier une quantité ou consulter le statut d'une commande.

D. Exécution locale avec Ollama

Un avantage important est la possibilité d'exécuter le modèle sur une infrastructure contrôlée par l'entreprise.
Cela peut apporter :

- Une meilleure maîtrise des flux de données.
- Une réduction de la dépendance aux API de fournisseurs externes.
- Une possibilité de fonctionnement sans connexion à un service LLM distant.
- Une maîtrise des coûts d'inférence.

Attention : l'utilisation d'Ollama en local ne garantit pas automatiquement la sécurité. Il faudra également prévoir la gestion des accès, le chiffrement, les journaux, les sauvegardes et la protection des données clients.

Tableau comparatif des modèles

Critères	Qwen 2.5 1.5B	Llama 3.2 1B	Gemma 2 2B	SmolLM2 1.7B
Développeur	Alibaba	Meta	Google	Hugging Face
Nombre de paramètres	1,5B	1B	2B	1,7B
Taille sur Ollama	986 Mo	1,3 Go	1,6 Go	Environ 1,1 Go
Langues	Multilingue	8 langues officiellement	Multilingue	Principalement anglais
Contexte maximal annoncé	32K tokens	128K tokens	8K tokens	8K tokens
Utilisation sur machine modeste	Très adaptée	Très adaptée	Adaptée	Très adaptée
Exécution locale avec Ollama	Oui	Oui	Oui	Oui

Qwen 2.5 1.5B présente plusieurs avantages pour notre projet :

- Faible consommation de ressources : seulement environ 986 Mo à télécharger.
- Compréhension multilingue : intéressant pour traiter des demandes formulées en français.
- Taille réduite : adapté à une utilisation locale sur des machines peu performantes.
- Intégration avec Python : utilisable via Ollama pour transmettre les demandes à notre programme.

Il représente donc un compromis intéressant entre légèreté et fonctionnalités pour notre interface de commande.